



# Birth-Death Process

## Transition Matrix P of Discrete Markov Process

離散時間的 Markov Chain 才使用轉移矩陣 P。

P 指的是狀態轉移機率的矩陣，準確地說，是針對當下時刻，轉移到下一狀態的機率。也可以理解成一步轉移的機率。舉例，從狀態 a 轉移到狀態 a 的機率，從狀態 a 轉移到狀態 b 再轉移到狀態 a 的機率。本質都是從狀態 a 轉移到狀態 a，但前者是一步轉移，後者是兩步轉移。因此如果只是轉移一步，那麼就根據 P 這個矩陣，若是轉移兩步，則根據  $P^{(2)}$ ，兩者的關係是  $P^{(2)} = P \cdot P$ ，這部分需要看到 **Chapman-Kolmogorov Equation**，是機率的部分，這邊不過多解釋。

因此我們可以知道轉移 n 步，也就是轉移 n 次時的狀態轉移機率。就是說狀態 a 轉移了 n 次之後，會轉移到各個狀態的機率。如下面這個轉移矩陣是一步的轉移矩陣。

$$P = \begin{bmatrix} p_{11} & p_{12} & p_{13} & \dots & p_{1n} \\ p_{21} & \ddots & & & \vdots \\ p_{31} & & \ddots & & \vdots \\ \vdots & & & \ddots & \vdots \\ p_{n1} & p_{n2} & p_{n3} & \dots & p_{nn} \end{bmatrix}$$

$$P^{(m)} = P \cdot P \cdot P \dots P = P^m$$

到此，應該對穩態有一個認知，不妨這樣去理解狀態 a 經過 n 次轉移回到 a 的機率，其實就是在說系統達到穩定時，處於狀態 a 的機率，只要 n 足夠大，就說明時間足夠長。

只要有 P 就可以求系統的穩態。我們現在定義系統處於穩態時，處於各狀態的機率記作  $\pi$ ，舉例，系統只有 a, b 兩個狀態， $(\pi_a, \pi_b) = (0.4, 0.6)$ ，說明穩態時，系統處於 a 狀態的機率是 0.4，處於 b 狀態的機率是 0.6，於是有下面這個公式，

$$\lim_{m \rightarrow \infty} p_{ab}^m = \pi_b$$

為什麼引入  $\pi$ ？因為表示形式是不一樣的，假如系統只有兩個狀態，那麼  $\pi$  就只有兩個元素，而 P 是一個 2x2 的矩陣。 $\pi$  是一種更直觀的表示方法來表示穩態時系統的狀況，稱為穩定狀態分配機率。



- 理論上系統的穩態其實跟系統的初始狀態無關。假設我們先前觀測到系統處於 a 狀態的機率為 0.2，處於 b 狀態的機率為 0.8，記作 $(\pi_a, \pi_b) = (0.2, 0.8)$ ，(所謂的觀測，就是計數，用人眼去記錄一段時間內 a, b 出現的次數，這個就是系統的初始狀態)。現在我們知道了狀態轉移矩陣 P，看到如下兩個例子。不管初始狀態觀測的是怎樣 (圖中一個是 0.6, 0.4，一個是 0.1, 0.9)，最後迭代出來的結果都是一樣的，也就是說只要轉移矩陣 P，系統的穩態就確定。這個迭代式就是

$$\pi = \pi \cdot P$$

```
dot.py > ...
1 import numpy as np
2
3 if __name__ == '__main__':
4
5     pi = np.array([[0.6, 0.4]])
6     P = np.array([[0.2, .8], [0.9, 0.1]])
7     tmp = pi.dot(P)
8     for i in range(100):
9         c = tmp.dot(P)
10        tmp = c
11    print(tmp)
```

TERMINAL PROBLEMS OUTPUT DEBUG CONSOLE


avisdeMacBook-Pro-10:maotai avis\$ python dot.py  
[0.52941176 0.47058824]  
avisdeMacBook-Pro-10:maotai avis\$

```
dot.py > ...
1 import numpy as np
2
3 if __name__ == '__main__':
4
5     pi = np.array([0.1, 0.9])
6     P = np.array([[0.2, .8], [0.9, 0.1]])
7     tmp = pi.dot(P)
8     for i in range(100):
9         c = tmp.dot(P)
10        tmp = c
11    print(tmp)
```

TERMINAL PROBLEMS OUTPUT DEBUG CONSOLE


avisdeMacBook-Pro-10:maotai avis\$ python dot.py  
[0.52941176 0.47058824]  
avisdeMacBook-Pro-10:maotai avis\$

- 以上這個 P 對應的 Markov Chain 如下圖



## Q Matrix of Continuous-Parameters Markov Process

離散時間馬可夫過程和連續時間馬可夫過程只是時間的差別，剛剛一直在講轉移了多少次，是因為時間是離散的，即  $t=0,1,2,\dots$ 。當然時間是連續的 ( $t>0$ )，就沒有多少次這個說法了。




假設  $p_{ac}(u, s)$  表示從  $u$  時刻開始，從 a 狀態，在  $s$  時刻到達狀態 c，有



$$p_{ac}(u, s) = \sum_b p_{ab}(u, t) p_{bc}(t, s) \quad (1)$$

可見下圖幫助理解上式，最下層的機率 sum 為 1。Sum 的原因是從 a 出發，下一個狀態不止一個，有可能到 b1，有可能到 b2。



令上式  $u=0$ ，有，

$$p_{ac}(0, t + \Delta t) = \sum_b p_{ab}(0, t) p_{bc}(t, t + \Delta t) \quad (2)$$

假設在 0 時刻的狀態是  $i$ ，有

$$p_c(t + \Delta t) = \sum_b p_b(t) p_{bc}(t, t + \Delta t) \quad (3)$$

因為是 Poisson Process，有，

$$p_{bc}(t, t + \Delta t) = \begin{cases} \lambda \Delta t + o(\Delta t), & \text{where } (b = c - 1, c \geq 1) \\ 1 - \lambda \Delta t + o(\Delta t), & \text{where } (b = c) \\ o(\Delta t), & \text{otherwise} \end{cases} \quad (4)$$

上面的式子之所以是  $\lambda \Delta t$ ，是說  $b$  和  $c$  之間發生了一次轉移，意思就是事件發生了一次。 $\lambda \Delta t$  是事件在  $\Delta t$  內發生了一次的機率。從 Poisson Distribution 的 PDF 可知。

$$P(X = k) = \frac{(\lambda t)^k e^{-\lambda t}}{k!}$$

當  $k=1$ ， $t = \Delta t$

$$P(X = 1) = \frac{(\lambda \Delta t)^1 e^{-\lambda \Delta t}}{1!} = \lambda \Delta t$$

因為  $e^{-\lambda \Delta t} = e^{-0} = 1$



也符合了 Poisson Process 的第一個特性，


✓ 在一個短時間區間  $\Delta t$  內，發生一次事件的機率與  $\Delta t$  成正比： $\lambda \Delta t$ 。

### 現在引入 $q$

$$q_{ij} = \lim_{\Delta t \rightarrow 0} \frac{Pr\{X(t + \Delta t) = j | X(t) = i\}}{\Delta t}$$

- 這是一個機率的比率(這個概念需要接受)
- 系統從狀態  $i$  轉移到狀態  $j$  的單位時間的概率 (probability per time unit that the system makes a transition from state  $i$  to state  $j$ )
- transition rate or transition intensity (書本的說法)
- 為什麼引入  $q$ ，用  $P$  不好嗎？ $P$  的測量依賴時間，觀測時間越長， $P$  越準確，但是觀測的時間不同的時候，結果就會有誤差。
- 上面的式子完全就是一個“密度”的思想，分子那一項越大， $q$  就越大，反映的就是說事件發生的次數在  $\Delta t$  內很多。那麼其實只要知道這個密度，就可以知道這個  $P$  (聯想一下，我們知道水的密度，給你一個已知道體積的大水缸，我們就可以知道這缸水的質量，這邊是一樣的概念。)
- $q$  這個概念因此不再依賴於時間，可以理解成依然是一個機率，但還是要和  $P$  做一個區分，我們可以把它理解成是一個稱為“流入率、流出率”的東西。為什麼要做區分？因為我們早把問題做了離散和連續的定義，連續的話就要把時間這個維度考慮進去。
- 知乎上的一個說法，值得參考。<https://www.zhihu.com/question/45532797?sort=created>

### 生滅過程



顧名思義，即狀態的生死過程，有一種在描述狀態的生命周期的感覺。實際上， $q$  可以看作是一種生命周期的概念。我們先前講的  $P$ ，例如  $p_{ab} = 0.7$ ，說的就是從狀態  $a$  轉移到狀態  $b$  這就是發生的機率是 0.7。機率其實就是一段時間內的數數，若總事件量是 100，那麼狀態  $a$



轉移到狀態 b 這件事就發生 70 次。

現在用  $q$  來理解，我把時間分成 100 秒，假設每秒發生一個事件，要想  $p_{ab} = 0.7$ ，那麼就是有 70 秒發生狀態 a 到狀態 b 的轉移。從零開始，發生 1 次，就還剩下 69 次沒完成，也就是說你的總量必須是 70 次。我們借用速率的概念，就是你一共要跑 70 米，每秒跑 1 米，你的速率就是  $1/70$ ，意思就是說你現在正以  $1/70$  的速率朝著狀態 b 轉移，也就是說你會以  $1/70$  的速率與狀態 a 漸行漸遠。因此我們可以感受到用一種狀態的 lifetime 的感覺。

當然這只是站在一個角度去看，狀態 a 轉移到狀態 b 說明了狀態 a 生命的減少，那麼狀態 b 轉移到狀態 a 就是說明狀態 a 生命的增加。因此 a 有付出也有收穫，付出和收穫維繫這狀態 a 的生命，因此我們會引入“流入率/流出率的概念”。狀態 a 之所以可以存在，是因為他不可以全是流出而沒有流入，換句話說要想維繫整個系統的穩定，狀態的流出一定要等於他的流入。

上面的例子，我們可以用矩陣表示，

$$Q = \begin{bmatrix} q_{aa} & q_{ab} & q_{ac} \\ q_{ba} & q_{bb} & q_{bc} \\ q_{ca} & q_{cb} & q_{cc} \end{bmatrix} = \begin{bmatrix} -\lambda & \lambda & 0 \\ \mu & -(\lambda + \mu) & \lambda \\ 0 & \mu & -\mu \end{bmatrix}$$

延續先前資料的例子，系統狀態就是系統的人數，有 0, 1, 2, arrival 服從泊松分佈，service rate 服從指數分佈，因此有人到達，系統往前跳，有人被服務完，系統往後跳。

$$q_{aa} = q_a \quad (\text{為狀態 a 流出的總量})$$

$$q_a = \sum_{i \neq a} q_{ai}$$

生滅過程大概就到這邊，其中很多是一些較為感性的認知，望對理解有所幫助。更為詳盡的資料還需自己親自動手尋找，以下有一份資料可供參考。

[https://www.netlab.tkk.fi/opetus/s383143/kalvot/E\\_markov.pdf](https://www.netlab.tkk.fi/opetus/s383143/kalvot/E_markov.pdf)